

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Семантический анализ русскоязычных диалогов для задачи распознавания намерений с улучшением на базе предобученных моделей

Обучающийся: Шкаровский Владислав Семенович

Квалификация: Магистратура

Факультет/институт/кластер: Высшая школа цифровой культуры

Направление подготовки: 02.04.03 Математическое обеспечение и администрирование информационных систем

Образовательная программа: Аналитика данных

Группа: S4201

Руководитель ВКР: Малых Валентин Андреевич

Обучающийся

Шкаровский Владислав Семенович

Дата: 24.05.2026

ЗАДАНИЕ

Основные вопросы, подлежащие разработке:

Исходные данные

Открытый русскоязычный корпус диалоговых текстов;

Датасет, содержащий реплики пользователей и ответы собеседника, dialogsum-ru;

Научные публикации и обзоры по задачам семантического анализа текстов, распознавания намерений и анализу диалогов;

Документация по использованию предобученных языковых моделей для русского языка;

Методические материалы по обработке текстовых данных, оценке качества моделей и анализу результатов экспериментов.

Содержание работы

Исследование предметной области семантического анализа русскоязычных диалогов и распознавания намерений пользователей;

Анализ существующих подходов к обработке диалоговых данных и выявление их ограничений;

Изучение и выбор открытого набора данных, пригодного для решения поставленной задачи;

Разработка общей схемы подготовки, представления и анализа диалоговых текстов;

Исследование возможностей применения предобученных языковых моделей для семантического представления реплик;

Формирование универсального подхода к распознаванию намерений с учетом контекста диалога;

Экспериментальная проверка предложенного подхода и сравнение с базовыми методами;

Анализ полученных результатов и определение направлений дальнейшего развития работы.

Цель работы

Разработка и исследование универсального подхода к семантическому анализу русскоязычных диалогов для распознавания намерений пользователей на основе предобученных языковых моделей.

Задачи работы

Проанализировать современные методы семантического анализа диалогов и распознавания намерений пользователей.

Провести EDA на, датасете содержащим реплики пользователей и ответы собеседника, dialogsum-ru.

Определить требования к структуре и качеству данных, необходимых для решения задачи.

Разработать общую методику предварительной обработки текстов и подготовки данных к анализу.

Исследовать возможности использования предобученных языковых моделей для построения

семантических представлений.

Провести экспериментальную оценку качества предложенного подхода.

Форма представления материалов ВКР:

текст ВКР, презентация

Дата выдачи задания

06.04.2026

Согласовано:

Руководитель ВКР Малых Валентин Андреевич, ВШ ЦК, доцент (квалификационная категория "ординарный доцент"), неосн по совм.

АННОТАЦИЯ

Цель исследования

Разработать и эмпирически исследовать конвейер семантического анализа русскоязычных диалогов, обеспечивающий:

- (а) интерпретируемое тематическое представление корпуса в условиях большого числа уникальных свободных тем,
- (б) распознавание намерений на уровне отдельных реплик с использованием тематических кластеров как контекстного признака и предобученных языковых моделей.

Задачи, решаемые в ВКР

1. Провести разведочный анализ датасета DialogSum-RU: оценить объём, распределения длин, качество текста, особенности маркеров спикеров и поля topic.
2. Сравнить базовые подходы к тематическому моделированию (LDA, NMF) с подходом «эмбединги + UMAP + HDBSCAN», дополненным автоматической интерпретацией кластеров.
3. Сформулировать схему намерений на уровне реплик, отделяющую коммуникативную функцию (речевой акт) от тематического содержания.
4. Построить слабо размеченный датасет реплик с использованием эвристических правил.
5. Сравнить классические и нейросетевые модели классификации намерений: TF-IDF + логистическая регрессия, эмбединги предложений + логистическая регрессия, гибриды TF-IDF + тематический кластер.
6. Проанализировать ошибки моделей, выявить классы с систематически низким качеством, обозначить ограничения и направления дальнейшей работы.

Краткая характеристика полученных результатов

1. Разработан пайплайн тематического моделирования (эмбединги + UMAP + HDBSCAN + LLM-интерпретация), обеспечивающий выделение 208 семантических кластеров с показателем силуэта 0,7623 и долей шумовых записей 17,1% на корпусе из 14 460 диалогов.
2. Показано превосходство предложенного подхода над базовыми методами LDA и NMF по качеству разделения и интерпретируемости результатов.
3. Сформулирована схема из 14 классов речевых актов и построен слабо размеченный датасет из 4 722 реплик без ручной аннотации.
4. При сравнении моделей классификации намерений на уровне реплик лучший результат показала модель TF-IDF + логистическая регрессия (macro-F1 = 0,66); модель на плотных эмбедингах — macro-F1 = 0,38; гибриды TF-IDF + тематический кластер — macro-F1 =

0,61.

5. На уровне диалога лучший результат достигнут при файнтюнинге `rubert-tiny2` с весами классов ($\text{macro-F1} = 0,41$) в сценарии `clean` на выборке 1 246 диалогов с ручной разметкой.

6. Установлено, что добавление тематического кластера как признака не улучшает распознавание речевых актов, однако кластеры остаются ценным промежуточным представлением для формирования тематически чистых обучающих выборок.

Наличие публикаций по теме выпускной работы

Шкаровский В.С. Электронный сборник тезисов докладов XV КМУ - 2026 (Тезисы;)

Наличие выступлений на конференциях по теме выпускной работы

XV Конгресс молодых ученых Университета ИТМО, 06.04.2026 - 10.04.2026 (Конференция, статус - всероссийский)

Согласовано:

Руководитель ВКР Малых Валентин Андреевич, ВШ ЦК, доцент (квалификационная категория "ординарный доцент"), неосн по совм.

19.05.2026

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ.....	5
ВВЕДЕНИЕ.....	7
Степень разработанности темы.....	8
Цель и задачи.....	9
Объект и предмет исследования.....	10
Научная новизна.....	10
Практическая значимость.....	11
Методы исследования.....	11
Апробация результатов.....	11
1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ РЕШЕНИЙ.....	12
1.1 Распознавание намерений в диалоговых системах.....	12
1.2 Намерение диалога и намерение реплики.....	13
1.3 Тематическое моделирование как контекст для интенгов.....	14
1.4 Подходы к моделированию: классические, нейросетевые, многоязычные.....	15
1.5 Особенности обработки русскоязычных диалогов.....	16
1.6 Слабая разметка и rule-based подходы.....	17
2 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ПРИМЕНЯЕМЫХ МЕТОДОВ.....	18
2.1 TF-IDF: математическая формализация и практика применения.....	18
2.2 Латентное распределение Дирихле (LDA).....	19
2.3 Неотрицательная матричная факторизация (NMF).....	21
2.4 UMAP: математические основы и алгоритм.....	23
2.5 Сравнительный анализ методов векторизации и снижения размерности.....	27
3 ОПИСАНИЕ DATASETА DIALOGSUM-RU.....	29
3.1 Происхождение и структура.....	29
3.2 Объём и сплиты.....	30
3.3 Поля и формат записей.....	30
3.4 Особенности и риски датасета.....	31
4 ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ (EDA).....	33
4.1 Цели и общие характеристики.....	33
4.2 Распределения длины диалогов и резюме.....	33
4.3 Анализ маркеров спикеров.....	34
4.4 Распределение поля topic.....	35

4.5 Качество текста и дубликаты.....	36
5 ТЕМАТИЧЕСКОЕ МОДЕЛИРОВАНИЕ.....	37
5.1 Постановка задачи.....	37
5.2 Базовые подходы: LDA и NMF.....	37
5.3 Основной подход: эмбединги + UMAP + HDBSCAN + интерпретация.....	38
5.4 Используемые модели и параметры.....	40
5.5 Результаты кластеризации и их интерпретация.....	41
5.6 Сравнение подходов.....	43
6 РАСПОЗНАВАНИЕ НАМЕРЕНИЙ.....	46
6.1 Концептуальное разделение: тема и речевой акт.....	46
6.2 Схема намерений (14 классов).....	46
6.3 Слабая разметка через эвристические правила.....	48
6.4 Формирование датасета и разбишка на выборки.....	49
6.5 Базовые модели и признаки.....	51
6.6 Предобученные языковые модели для классификации намерений..	53
7 ЭКСПЕРИМЕНТАЛЬНЫЕ РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ.....	55
7.1 Метрики оценки.....	55
7.1 Метрики оценки.....	55
7.2 Результаты на уровне диалога.....	56
7.3 Результаты на уровне реплик.....	58
7.4 Анализ ошибок.....	60
7.5 Влияние тематического контекста на качество классификации.....	61
8 ОГРАНИЧЕНИЯ ИССЛЕДОВАНИЯ.....	63
8.1 Слабая разметка.....	63
8.2 Дисбаланс классов.....	63
8.3 Дубликаты и перекрытие сплитов.....	63
8.4 Качество машинного перевода.....	64
8.5 Ограничения вычислительных ресурсов.....	64
8.6 Ограничения методов TF-IDF, LDA и NMF.....	64
ЗАКЛЮЧЕНИЕ.....	66
Перспективы дальнейших исследований.....	68
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	70
ПРИЛОЖЕНИЕ А.....	76
ПРИЛОЖЕНИЕ Б.....	78
ПРИЛОЖЕНИЕ В.....	82

ПРИЛОЖЕНИЕ Г.....	85
--------------------------	-----------

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ВКР — выпускная квалификационная работа

ИИ — искусственный интеллект

НЛП / NLP — обработка естественного языка (Natural Language Processing)

BERT — двунаправленные представления из трансформеров (Bidirectional Encoder Representations from Transformers)

RuBERT — русскоязычная версия модели BERT

XLM-R — кросслингвальная модель на основе RoBERTa (Cross-lingual Language Model — RoBERTa)

TF-IDF — частотность терминов — обратная частотность документов (Term Frequency — Inverse Document Frequency)

UMAP — равномерное приближение и проекция многообразия (Uniform Manifold Approximation and Projection)

HDBSCAN — иерархический алгоритм плотностной кластеризации с шумом (Hierarchical Density-Based Spatial Clustering of Applications with Noise)

LDA — латентное распределение Дирихле (Latent Dirichlet Allocation)

NMF — неотрицательная матричная факторизация (Non-negative Matrix Factorization)

BiGRU — двунаправленная рекуррентная сеть с управляемыми вентилями (Bidirectional Gated Recurrent Unit)

EDA — разведочный анализ данных (Exploratory Data Analysis)

SOTA — наилучший достигнутый результат (State of the Art)

macro-F1 — среднее арифметическое F1-меры по всем классам

F1 — гармоническое среднее точности и полноты (F1-score)

GPU — графический процессор (Graphics Processing Unit)

CPU — центральный процессор (Central Processing Unit)

LLM — большая языковая модель (Large Language Model)

MT — машинный перевод (Machine Translation)

BoW — мешок слов (Bag of Words)

SVD — сингулярное разложение матрицы (Singular Value Decomposition)

EM — алгоритм максимизации ожидания (Expectation-Maximization)

KL — дивергенция Кульбака — Лейблера (Kullback-Leibler divergence)

ВВЕДЕНИЕ

Современные диалоговые системы — голосовые ассистенты, чат-боты служб поддержки, системы маршрутизации обращений — критически зависят от качества распознавания намерений пользователя. Под намерением (intent) понимают компактное семантическое представление того, чего хочет пользователь: получить информацию, выполнить покупку, пожаловаться, договориться о действии и т. д. Корректно распознанное намерение позволяет системе выбирать ветвь сценария, обращаться к нужному источнику данных или эскалировать обращение оператору.

Актуальность темы определяется тем, что подавляющее большинство публично доступных корпусов для распознавания намерений собрано на английском языке. Для русского языка ситуация осложняется тремя обстоятельствами. Во-первых, корпусов с заранее заданной таксономией намерений и качественной разметкой существенно меньше. Во-вторых, богатая морфология и относительно свободный порядок слов снижают эффективность наивных лексических подходов. В-третьих, реальные диалоги характеризуются неоднородностью: в одной беседе смешиваются приветствия, уточнения, жалобы, согласия и договорённости, что затрудняет приписывание единой метки целому диалогу.

Параллельно с задачей классификации намерений возникает задача организации тематического пространства диалогов: реальные корпуса содержат тысячи уникальных коротких тематических меток или вовсе свободные краткие описания тем. В такой ситуации тематическое моделирование выступает не как самоцель, а как инструмент построения

промежуточного представления, служащего контекстом для распознавания намерений.

Степень разработанности темы

Задача распознавания намерений активно исследуется с конца 2010-х годов. В работах на английском языке трансформерные модели серии BERT демонстрируют высокую точность на устоявшихся бенчмарках (ATIS, SNIPS). Для русского языка были разработаны RuBERT [1] и rubert-tiny2 [2], а также многоязычные модели XLM-RoBERTa и paraphrase-multilingual-MiniLM-L12-v2 [3]. Работы по тематическому моделированию диалогов включают исследования BERTopic-подобных подходов [4, 5], сравнительные исследования LDA, NMF и нейросетевых методов [6]. Вместе с тем работ, объединяющих тематическое моделирование и распознавание намерений в едином конвейере для русскоязычных диалогов, практически нет.

Применение классических методов векторизации текста, прежде всего TF-IDF, к задачам диалогового анализа на русском языке сопряжено с рядом нетривиальных вопросов. С одной стороны, TF-IDF сохраняет интерпретируемость и вычислительную эффективность; с другой — он слеп к синонимии и морфологическим вариантам. Аналогичная дилемма возникает при выборе между вероятностными тематическими моделями (LDA, NMF) и современными подходами на плотных эмбедингах с последующей кластеризацией (UMAP + HDBSCAN). Сравнение этих подходов на одном русскоязычном корпусе составляет ключевой вклад данной работы.

Цель и задачи

Цель работы — разработать и эмпирически исследовать конвейер семантического анализа русскоязычных диалогов, обеспечивающий интерпретируемое тематическое представление корпуса и распознавание намерений на уровне реплик с использованием предобученных языковых моделей.

Для достижения цели поставлены следующие задачи:

1. провести разведочный анализ датасета DialogSum-RU: оценить объём, распределения длин, качество текста, особенности маркеров спикеров и поля topic;
2. детально исследовать методы векторизации текста (TF-IDF, BoW) и тематического моделирования (LDA, NMF), выявить их математические основания и ограничения применительно к коротким русскоязычным текстам;
3. сравнить базовые подходы к тематическому моделированию (LDA, NMF) с подходом «эмбединги + UMAP + HDBSCAN», дополненным автоматической интерпретацией кластеров;
4. детально изучить алгоритм снижения размерности UMAP, обосновать выбор его гиперпараметров и проанализировать влияние топологической структуры данных на качество кластеризации;
5. сформулировать схему намерений на уровне реплик, отделяющую коммуникативную функцию от тематического содержания;
6. построить слабо размеченный датасет реплик с использованием эвристических правил;

7. сравнить классические (TF-IDF + логистическая регрессия) и нейросетевые (файнтюнинг предобученных трансформеров) модели классификации намерений;

8. проанализировать ошибки моделей и выявить классы с систематически низким качеством.

Объект и предмет исследования

Объект исследования — русскоязычные диалоги в формате «диалог + краткое резюме + свободная тема», представленные датасетом DialogSum-RU (d0rj/dialogsum-ru).

Предмет исследования — методы тематической организации диалогов и методы распознавания намерений в репликах в условиях ограниченной разметки, включая использование тематических кластеров как контекстного признака, а также математические свойства алгоритмов TF-IDF, LDA, NMF и UMAP применительно к коротким русскоязычным текстам.

Научная новизна

Научная новизна работы состоит в следующем: (1) на материале одного русскоязычного корпуса впервые совместно сравниваются тематическая кластеризация и классификация намерений; (2) эмпирически показано, что в условиях слабой разметки лексические признаки (TF-IDF) превосходят плотные эмбединги предложений в задаче классификации речевых актов; (3) предложено использование пары «тематический кластер — речевой акт» как интерпретируемого представления диалога; (4) проведён детальный сравнительный анализ математических свойств LDA, NMF и UMAP применительно к коротким морфологически богатым текстам на русском языке.

Практическая значимость

Разработанный конвейер может применяться при проектировании русскоязычных диалоговых систем: тематические кластеры выступают как фасеты домена для маршрутизации, а классификатор намерений на уровне реплик — как сигнал управления диалогом. Промежуточные артефакты (таблица кластеров, разметка реплик, обученные базовые модели) пригодны для переиспользования. Детальное описание математических основ методов и практических ограничений позволяет исследователям обоснованно выбирать алгоритм для конкретной задачи.

Методы исследования

В работе применяются методы разведочного анализа данных, тематического моделирования (LDA, NMF, HDBSCAN-кластеризация в пространстве эмбедингов), слабого обучения с учителем, классификации на основе TF-IDF признаков и плотных векторных представлений, файнтюнинга предобученных языковых моделей. Математическое обоснование методов включает формальные определения TF-IDF весов, вероятностных порождающих моделей LDA и NMF, а также топологических конструкций, лежащих в основе UMAP.

Апробация результатов

Основные результаты работы прошли проверку через сравнение с baseline-методами на общедоступном датасете, что обеспечивает воспроизводимость. Программный код и артефакты зафиксированы в системе контроля версий и доступны для проверки.

1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ И СУЩЕСТВУЮЩИХ РЕШЕНИЙ

1.1 Распознавание намерений в диалоговых системах

Задача распознавания намерений (intent detection, intent classification) исторически возникла в диалоговых системах с обработкой естественного языка как задача отображения пользовательской реплики во множество заранее определённых классов действий или запросов [7]. В классической постановке таксономия намерений задаётся заранее, обучающая выборка состоит из коротких реплик, каждой из которых приписана одна метка. Наиболее часто применяемые метрики — общая точность (ассигасу), macro-F1 и weighted-F1.

Со временем задача расширилась в двух направлениях. Во-первых, появились многосегментные диалоги, в которых намерение приходится распознавать не у одной реплики, а у последовательности реплик. Во-вторых, в реальных продуктовых сценариях возникает потребность работать в открытых таксономиях с иерархическими и пересекающимися классами. Работы Legashev et al. [8] показали, что подход на базе BERT-трансформера достигает показателя $F1 = 0,78$ на задачах классификации намерений по сравнению с $0,65$ у логистической регрессии на TF-IDF признаках.

Стандартные англоязычные бенчмарки — ATIS (набор данных аэропортовых запросов) и SNIPS (набор командных диалогов голосового ассистента) — содержат чётко разграниченные однозначные интен- ты. На этих датасетах современные трансформерные модели достигают ассигасу выше $0,99$. Однако перенос таких результатов на свободные диалоги других доменов и языков сопряжён с существенной деградацией качества из-за многозначности, коротких реплик и нехватки обучающих данных.

1.2 Намерение диалога и намерение реплики

С точки зрения уровня анализа различают два варианта задачи. Намерение всего диалога (dialogue-level intent) — компактная характеристика беседы в целом: «обсуждение работы», «покупка или заказ», «жалоба». Это представление удобно для агрегированной аналитики и маршрутизации, однако для длинных, многотемных диалогов оно может быть плохо определённым: одна беседа способна совмещать приветствия, договорённости, информационные запросы и завершение.

Намерение реплики (utterance-level intent), или речевой акт, — характеристика отдельной реплики: «приветствие», «просьба об информации», «подтверждение», «отказ», «жалоба». Это представление более устойчиво к смещению тем и хорошо ложится на классические перечни речевых актов (speech acts), введённые ещё в работах Остина и Сёрля [9]. В настоящей работе акцент делается именно на распознавание намерений на уровне реплик, при этом тематическая принадлежность всего диалога используется как дополнительный контекстный признак.

Теория речевых актов, восходящая к философии языка Остина и Сёрля, разделяет высказывание на локутивный акт (само произнесение), иллокутивный акт (намерение говорящего — предупредить, пообещать, попросить) и перлокутивный акт (воздействие на слушателя). Применительно к диалоговым системам иллокутивная сила реплики соответствует тому, что принято называть интендом или речевым актом. Таксономии речевых актов для диалоговых систем (например, ISO 24617-2) насчитывают от 9 до нескольких десятков базовых категорий.

1.3 Тематическое моделирование как контекст для интенгов

Тематическое моделирование традиционно ассоциируется с алгоритмами LDA [10] и NMF [11], которые оперируют мешком слов и выдают распределения тем по документам. В диалоговых корпусах эти подходы сталкиваются с ограничениями: краткость реплик, морфологическое богатство русского языка, размытость границ между близкими темами. Кроме того, LDA и NMF требуют заблаговременного задания числа тем k , что нетривиально без предварительного анализа данных.

Альтернативный современный подход [12] включает четыре шага: (1) каждый документ преобразуется в плотный вектор с помощью многоязычной модели предложений; (2) пространство снижается до низкой размерности с помощью UMAP [13]; (3) применяется HDBSCAN [14], который автоматически определяет число кластеров; (4) кластеры интерпретируются с помощью характерных n -грамм и языковой модели. Этот пайплайн, широко известный под названием BERTopic [15], обладает устойчивостью к синонимии, автоматически обнаруживает структуру и поддерживает применение к новым данным.

Сравнительное исследование Egger [6] показало, что BERTopic превосходит LDA и NMF по качеству и интерпретируемости на коротких текстах, подобных диалогам. NMF занимает второе место, а LDA уступает обоим из-за ограничений модели «мешка слов» при работе с короткими, морфологически разнообразными текстами. Данные выводы согласуются с теоретическими ограничениями LDA: при небольшом числе токенов в документе статистические оценки распределений тем оказываются ненадёжными.

1.4 Подходы к моделированию: классические, нейросетевые, многоязычные

На стороне классификации намерений выделяют три семейства подходов. Первое — классические лексические модели на основе TF-IDF и линейных классификаторов (логистическая регрессия, линейные SVM). Они отличаются простотой, прозрачностью и устойчивостью при ограниченном объёме данных. Их слабость — опора на поверхностную лексику: неспособность учитывать синонимию, полисемию и контекст.

Второе семейство — модели на плотных эмбедингах. Реплика кодируется предобученной моделью (например, многоязычный sentence-transformer paraphrase-multilingual-MiniLM-L12-v2 [3]), а классификатором служит логистическая регрессия. Эмбединги хорошо улавливают синонимию, но при слабой и лексически предсказуемой разметке могут уступать TF-IDF, поскольку семантическая близость эмбедингов не соответствует лексической близости ключевых слов-маркеров.

Третье семейство — файнтюнинг BERT-подобных энкодеров, в том числе русскоязычных (RuBERT [1], rubert-tiny2 [2]) и многоязычных (XLM-RoBERTa [16], multilingual MiniLM [3]). Они потенциально дают наилучшее качество, но требуют значительных вычислительных ресурсов. Отдельно стоит упомянуть RuModernBERT [17] — современную русскоязычную модель, специально оптимизированную для классификации интенгов в диалоговых системах. Архитектура трансформерных моделей базируется на механизме само-внимания, который позволяет при вычислении представления очередного токена опираться не на фиксированное окно, а на всю последовательность входных токенов. Такое устройство внимания делает возможным учёт как

ближнего, так и дальнего контекста в пределах предложения или реплики диалога.

1.5 Особенности обработки русскоязычных диалогов

Для русскоязычных диалогов к моделям предъявляются дополнительные требования, связанные с языковыми особенностями. Богатая флективная морфология в сочетании с относительно свободным порядком слов ухудшает качество простых пословных методов: одна лексема в реальной речи реализуется множеством словоформ, и без лемматизации каждая из них превращается в отдельный токен в словаре TF-IDF, увеличивая размерность и разреженность представлений. Дополнительную сложность создаёт то, что маркеры говорящих в корпусах диалогов зачастую задаются в произвольном формате (например, #Person1#, #Человек1#, #Лицо1#), и их приходится унифицировать на этапе предобработки. Наконец, грамматикализованные средства вежливости (обращение «вы», формулы приветствия и уважительного обращения) дают сильные лексические подсказки при выделении актов приветствия, этикетных реплик и формального обращения к собеседнику.

Библиотека DeepPavlov включает набор предобученных моделей для задач обработки русского языка, в том числе модификацию RuBERT, адаптированную под диалоговые данные (Conversational RuBERT), обученную на корпусах неформального общения и субтитрах. Благодаря такой специализации модель хорошо подходит для задач понимания реплик и распознавания намерений в разговорных диалогах; вместе с тем в последнее время всё чаще рассматриваются большие языковые модели, способные решать классификационные задачи в zero-shot и few-shot постановках, когда обучение на специально размеченном наборе диалогов либо сильно сокращается, либо полностью отсутствует.

1.6 Слабая разметка и rule-based подходы

Поскольку разметка крупных корпусов вручную требует значительных временных и финансовых затрат, на практике часто используют методы слабого обучения (weak supervision). В системах типа Snorkel набор эвристических правил, основанных на экспертных знаниях (функции разметки, *labeling functions*), автоматически присваивает объектам предполагаемые метки. Такой подход позволяет быстро получить большие обучающие выборки, однако порождает систематическую привязку меток к определённым лексическим признакам, из-за чего сравнение моделей, опирающихся на лексические и семантические представления, оказывается смещённым. В работе *Comparing Weak Supervision and LLMs* показано, что слабая разметка на основе ключевых слов и простых эвристик даёт достаточно приемлемое качество для грубой классификации, но заметно проигрывает как человеческой аннотации, так и разметке с использованием больших языковых моделей при разграничении близких по смыслу классов.

В контексте данной работы это ограничение особенно значимо: схема из 14 классов речевых актов содержит потенциально пересекающиеся категории (например, *informational_request* и *service_request*), граница между которыми определяется прагматическим намерением говорящего, а не лексической поверхностью.

2 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ПРИМЕНЯЕМЫХ МЕТОДОВ

2.1 TF-IDF: математическая формализация и практика применения

TF-IDF (Term Frequency — Inverse Document Frequency) — взвешенная схема представления текста в виде вектора, в которой вес каждого термина отражает его локальную частоту в документе и глобальную редкость в коллекции. Метод был введен Спарком Джонсом [38] и до сих пор остаётся конкурентоспособным базовым методом для многих задач классификации текстов.

Пусть корпус состоит из N документов. Частота термина t в документе d определяется как отношение числа вхождений термина к общему числу слов документа: $TF(t, d) = f(t, d) / |d|$, где $f(t, d)$ — абсолютная частота. Обратная частота документа вычисляется как логарифм отношения числа документов к числу документов, содержащих термин: $IDF(t) = \log((N + 1) / (df(t) + 1)) + 1$ (сглаженная формула, применяемая в scikit-learn [38]). Итоговый TF-IDF вес: $w(t, d) = TF(t, d) \cdot IDF(t)$. После вычисления весов вектор документа нормируется до единичной L2-нормы.

Интуитивная интерпретация формулы такова: термины, встречающиеся часто в конкретном документе, но редко во всём корпусе, получают высокий вес и считаются информативными для этого документа. Стоп-слова и общеупотребительные выражения присутствуют во многих документах и получают низкий IDF-вес, автоматически теряя влияние на классификацию.

Практические аспекты применения TF-IDF к русскоязычным текстам включают несколько важных шагов предобработки. Во-первых,

лемматизация или стемминг снижают размерность словаря и объединяют морфологические варианты одного слова. Без лемматизации формы «купить», «купил», «купила», «купают» образуют четыре отдельных токена с независимыми весами, хотя семантически они эквивалентны. Во-вторых, удаление стоп-слов (служебных частей речи, предлогов, частиц) снижает шум в признаковом пространстве. В-третьих, n-граммные расширения (bigrams, trigrams) позволяют захватывать устойчивые словосочетания: «не работает», «хочу заказать», «добрый день».

Ограничения TF-IDF определяются моделью «мешка слов» (Bag of Words), на которой он основан: порядок слов полностью игнорируется, что делает невозможным различие «клиент жалуется на сотрудника» и «сотрудник жалуется на клиента». Синонимы и парафразы получают разные векторные представления: «можно узнать» и «хотел бы спросить» — разные наборы токенов с нулевым сходством в TF-IDF пространстве. Кроме того, метод не учитывает контекст: значение полисемичного слова одинаково в разных документах. Эти ограничения мотивируют переход к распределённым векторным представлениям на основе нейронных сетей.

В настоящей работе TF-IDF применяется на двух уровнях. На уровне тематического моделирования TF-IDF используется как часть пайплайна BERTopic для извлечения характерных ключевых слов кластера (с-TF-IDF: class-based TF-IDF, где «документом» служит конкатенация всех текстов кластера). На уровне классификации намерений TF-IDF является основой базовой модели A, показывающей наилучшие результаты среди трёх сравниваемых подходов.

2.2 Латентное распределение Дирихле (LDA)

Латентное распределение Дирихле (Latent Dirichlet Allocation, LDA), предложенное Блеем, Нгом и Джорданом в 2003 году [10], является

вероятностной порождающей моделью для коллекций документов. В основе LDA лежит предположение о том, что каждый документ представляет собой смесь нескольких скрытых тем, а каждая тема — вероятностное распределение над словарём. Модель является полностью генеративной: она задаёт распределение вероятностей над всеми возможными корпусами, что делает возможным вывод скрытых переменных по наблюдаемым данным.

Формально LDA описывается следующим порождающим процессом. Для корпуса из M документов и фиксированного числа тем K : для каждой темы $k = 1, \dots, K$ рисуется распределение слов $\phi_k \sim \text{Dirichlet}(\beta)$; для каждого документа $m = 1, \dots, M$ рисуется распределение тем $\theta_m \sim \text{Dirichlet}(\alpha)$; для каждой позиции n в документе m сначала рисуется тема $z_{\{m,n\}} \sim \text{Categorical}(\theta_m)$, затем рисуется слово $w_{\{m,n\}} \sim \text{Categorical}(\phi_{z_{\{m,n\}}})$. Гиперпараметры α и β управляют априорными распределениями Дирихле: малое α означает, что документы сосредоточены на немногих темах; малое β — что темы описываются немногими словами.

Вывод параметров LDA является задачей приближённого байесовского вывода: точное вычисление апостериорного распределения $p(\theta, z, \phi \mid w)$ вычислительно неприемлемо из-за суммирования по всем возможным назначениям тем. На практике применяются два подхода: вариационный ЕМ-алгоритм (используется в *gensim*) и коллапсированная выборка Гиббса (используется в *lda* и *Mallet*). Каждый из них имеет свои компромиссы по скорости сходимости и качеству приближения.

Основные ограничения LDA применительно к диалоговым корпусам следующие. Во-первых, LDA предполагает обмениваемость документов и слов (*bag-of-words*), игнорируя синтаксис и порядок. Во-вторых,

необходимость фиксировать число тем K заранее требует перебора или применения специальных методов выбора (когерентность, perplexity). В-третьих, при коротких документах (типичная реплика — 5--15 слов) оценки распределений тем статистически ненадёжны: слишком мало токенов для устойчивой оценки θ_m . В-четвёртых, LDA не выделяет «шумовые» документы — каждый диалог обязательно получит ненулевую вероятность для каждой из K тем, что снижает интерпретируемость при работе с тематически разнородными корпусами.

Тем не менее LDA остаётся ценным инструментом в сценариях, где интерпретируемость топ-слов тем важнее точности разграничения и где данных достаточно для устойчивых статистических оценок. В данной работе LDA применяется в конфигурациях $k=20$ и $k=40$ как базовый метод сравнения.

2.3 Неотрицательная матричная факторизация (NMF)

Неотрицательная матричная факторизация (Non-negative Matrix Factorization, NMF) — метод понижения размерности, предложенный Ли и Сёнгом в 1999 году [11]. В отличие от SVD (singular value decomposition), NMF накладывает ограничение неотрицательности на все элементы матриц-факторов, что обеспечивает естественную интерпретацию компонент как «частей» исходных объектов.

Формально задачу NMF можно сформулировать так. Пусть задана матрица

$$V \in \mathbb{R}^{n \times m}$$

где n — число документов, а m — размер словаря. Требуется найти неотрицательные матрицы

$$W \in \mathbb{R}_{\geq 0}^{n \times k}, \quad H \in \mathbb{R}_{\geq 0}^{k \times m}$$

такие, что выполняется приближённое равенство

$$V \approx WH$$

Число компонент k задаётся заранее и трактуется как количество тем; обычно предполагается, что

$$k \ll \min(n, m)$$

В этом случае матрицу W интерпретируют как матрицу «документ–тема» (аналог θ в LDA), а матрицу H — как матрицу «тема–слово» (аналог φ в LDA). Оптимизационная постановка сводится к задаче минимизации

$$\min_{W \geq 0, H \geq 0} \|V - WH\|_F^2$$

где $\|\cdot\|_F$ обозначает норму Фробениуса; вместо неё нередко рассматривают вариант на основе дивергенции Кульбака–Лейблера.

Алгоритмически NMF решается итерационными методами. Классический подход — мультипликативные правила обновления, предложенные Ли и Сингом, а также методы координатного спуска. Для квадратичной функции потерь мультипликативные обновления имеют вид

$$H \leftarrow H \odot \frac{W^T V}{W^T W H}, \quad W \leftarrow W \odot \frac{V H^T}{W H H^T}$$

где символ $\odot$ обозначает поэлементное произведение, а деление также понимается поэлементно. Эти правила гарантируют сохранение неотрицательности элементов матриц W и H и обеспечивают монотонное убывание значения целевой функции. При этом алгоритм, как

правило, сходится к одному из локальных минимумов, поэтому выбор начальной инициализации матриц существенно влияет на качество найденного разложения.

Сравнение NMF и LDA выявляет следующие различия. NMF является детерминированной (при фиксированной инициализации) оптимизационной процедурой, не предполагает вероятностной интерпретации компонент и опирается на алгебраическую структуру данных. LDA является вероятностной генеративной моделью с байесовским выводом, позволяющей получать апостериорные оценки неопределённости. На практике NMF часто даёт более чёткие и интерпретируемые темы на коротких корпусах, поскольку жёсткое неотрицательное ограничение способствует разреженным факторам.

Ключевое преимущество NMF перед LDA при работе с TF-IDF матрицами — учёт непрерывных весов документов вместо дискретных счётчиков слов. TF-IDF подавляет частотные слова-«шумы», что делает матрицу V более информативной для факторизации. Именно поэтому в BERTopic-подобных пайплайнах NMF применяется поверх TF-IDF, а не поверх BoW. В данной работе NMF исследуется в конфигурациях $k=20$ и $k=40$ как второй базовый метод.

2.4 UMAP: математические основы и алгоритм

UMAP (Uniform Manifold Approximation and Projection) — алгоритм снижения размерности, разработанный Макинисом, Хили и Мелвиллом в 2018 году [13]. В отличие от t-SNE [36], UMAP имеет строгое теоретическое обоснование в терминах теории топологических данных и теории категорий, сохраняет как локальную, так и глобальную структуру данных, поддерживает трансформацию новых точек (инкрементальный вывод) и значительно быстрее на больших данных.

Теоретически UMAP опирается на представление данных в виде нечёткого симплициального комплекса, аппроксимирующего топологию исходного пространства. Алгоритм удобно рассматривать как состоящий из двух последовательных этапов.

На первом этапе, в исходном пространстве признаков, для каждой точки x_i находятся k ближайших соседей. Далее расстояния нормируются относительно расстояния до ближайшего соседа (вводится параметр ρ_i)

после чего строится нечёткий взвешенный граф с весами рёбер

$$w(x_i, x_j) = \exp \left(- \frac{d(x_i, x_j) - \rho_i}{\sigma_i} \right)$$

где параметр σ_i подбирается так, чтобы суммарный вес рёбер вокруг точки соответствовал целевому числу соседей (гиперпараметр $n_{\text{neighbors}}$)

Полученный граф затем симметризуется по формуле

$$w_{\text{sym}} = w + w^T - w \cdot w^T$$

что обеспечивает согласованное представление взаимных связей между объектами.

На втором этапе формируется вложение в пространство меньшей размерности. Для этого минимизируется кросс-энтропия между нечётким симплициальным комплексом, построенным в исходном пространстве, и аналогичным комплексом во вложенном пространстве. Целевая функция обычно записывается в виде

$$C = \sum_{(i,j)} \left[w_{\text{high}} \log \frac{w_{\text{high}}}{w_{\text{low}}} + (1 - w_{\text{high}}) \log \frac{1 - w_{\text{high}}}{1 - w_{\text{low}}} \right]$$

где w_{high} обозначает веса рёбер исходного графа, а веса во вложенном пространстве задаются выражением

$$w_{\text{low}}(y_i, y_j) = (1 + a \|y_i - y_j\|^{2b})^{-1}$$

Минимизация этого функционала выполняется стохастическим градиентным спуском с использованием отрицательной выборки, что позволяет применять UMAP к большим наборам данных.

Выбор гиперпараметров UMAP во многом определяет характер итогового вложения, поэтому в настоящей работе он подчинён вполне конкретной задаче — обеспечить условия для последующей плотностной кластеризации, а не получить «красивую» проекцию как таковую.

Параметр `n_neighbors=15` задаёт баланс между локальной и глобальной структурой: при малых значениях (порядка 2–5) алгоритм фактически сводится к подчёркиванию локальных сгущений, тогда как значения в диапазоне 50–200, напротив, начинают воспроизводить глобальную топологию ценой размывания мелких групп. Выбранное значение — умеренный компромисс; оно ориентировано на выявление тематически связанных групп, но при этом не разрушает крупномасштабную организацию пространства. Параметр `min_dist=0.0` отвечает за плотность укладки точек, и здесь нулевое значение принято сознательно: оно позволяет точкам располагаться сколь угодно близко друг к другу, что напрямую играет на руку HDBSCAN, тогда как любые положительные значения, визуально «разносящие» кластеры, на практике лишь затрудняют их последующее обнаружение. Целевая размерность зафиксирована как `n_components=5`, а в качестве метрики исходного пространства выбрана косинусная (`metric='cosine'`) — естественное

решение для L2-нормализованных эмбеддингов, где угловая близость и без того согласована с семантическим сходством.

Сопоставление с t-SNE обнаруживает ряд принципиальных расхождений, причём не в пользу последнего. Прежде всего, базовый t-SNE не поддерживает трансформацию новых точек в уже построенное пространство без полного переобучения модели, что фактически исключает его использование в системах с инкрементальным пополнением данных — а именно такой сценарий предполагается в нашем случае. Помимо этого, UMAP заметно лучше масштабируется: его эмпирическая вычислительная сложность близка к $O(n^{1.14})$, тогда как стандартный t-SNE остаётся квадратичным — $O(n^2)$, — и на выборках интересующего нас порядка это различие из теоретического превращается в практически непреодолимое.

Стоит, впрочем, оговориться: UMAP не свободен от собственных издержек. Он действительно лучше сохраняет межкластерные расстояния, тогда как t-SNE концентрируется главным образом на локальной структуре, однако при малых `n_neighbors` UMAP способен порождать так называемые «ложные» кластеры, не имеющие опоры в исходных данных, — явление, обозначаемое в литературе как топологический шум [Healy & McInnes, 2024]. Этим, в частности, объясняется наш отказ от значений в нижней части допустимого диапазона.

В рамках тематического моделирования UMAP выполняет, по существу, роль переходного звена между высокоразмерным пространством семантических эмбеддингов (384 измерения) и низкоразмерным пространством (5 измерений), пригодным уже для плотностной кластеризации средствами HDBSCAN. Сама необходимость снижения размерности здесь не декоративна, а методологически обязательна: в

высокоразмерных пространствах расстояния между точками стремятся к одному и тому же значению — проявление пресловутого «проклятия размерности», — а вместе с этим теряет содержательный смысл и само понятие плотности, на котором строится последующая кластеризация.

2.5 Сравнительный анализ методов векторизации и снижения размерности

Для систематизации рассмотренных подходов целесообразно сравнить их по нескольким ключевым параметрам. Таблица 1 содержит сводное сравнение TF-IDF, LDA, NMF и UMAP+Embeddings по критериям, существенным для задачи тематического моделирования диалогов.

Таблица 1 — Сравнение методов представления и тематического моделирования текста

Критерий	TF-IDF	LDA	NMF	Эмбединги + UMAP
Вход	Токены	BoW счётчики	TF-IDF матрица	Плотные векторы
Число тем	Нет	Задаётся вручную	Задаётся вручную	Определяется автоматически
Синонимия	Не учитывается	Частично	Частично	Хорошо

Морфология RU	Требуется лемматизация и	Требуется лемматизация и	Требуется лемматизация и	Встроена в трансформер
Выбросы	Нет	Нет	Нет	Кластер -1 в HDBSCAN
Интерпретируемость	Высокая	Высокая	Высокая	Средняя (через LLM)
Новые точки	Да	Да (vb-EM)	Да	Да (UMAP transform)
Скорость	Очень быстро	Медленно	Быстро	Медленно (эмбединги)

3 ОПИСАНИЕ DATASETA DIALOGSUM-RU

3.1 Происхождение и структура

В работе используется корпус d0rj/dialogsum-ru [37] — русскоязычная локализация англоязычного датасета DialogSum [22]. DialogSum представляет собой корпус коротких диалогов с привязанным к каждому диалогу кратким резюме (summary) и свободно сформулированной темой (topic). Данные были собраны из трёх публичных диалоговых корпусов: DailyDialog [23], DREAM [24] и MuTual, а также с англоязычного сайта разговорной практики. Русскоязычная версия сохраняет структуру оригинала, сопровождая каждый диалог переведённым резюме и темой.

Оригинальный DialogSum состоит из 13 460 диалогов и охватывает повседневные жизненные темы: работу, медицину, покупки, отдых, путешествия [22]. Диалоги ведутся между двумя сторонами и отражают реальные разговорные ситуации с характерными для устной речи эллипсисом, кореференцией и прагматическими импликатурами. Тематическое разнообразие корпуса делает его ценным объектом для изучения как тематического моделирования, так и классификации речевых актов, поскольку в нём представлен широкий спектр коммуникативных ситуаций.

Выбор DialogSum-RU как основного датасета обусловлен рядом факторов. Во-первых, наличие поля topic с тысячами уникальных значений создаёт естественную задачу тематической кластеризации. Во-вторых, наличие кратких резюме открывает перспективы для автоматической генерации описаний кластеров. В-третьих, корпус достаточно велик (14 460 диалогов) для статистически значимых выводов, но достаточно мал

для обработки на доступных вычислительных ресурсах без распределённых систем.

3.2 Объём и сплиты

Датасет d0rj/dialogsum-ru разбит на три стандартных сплита. Обучающий (train) содержит 12 460 диалогов, валидационный (validation) — 500 диалогов, тестовый (test) — 1 500 диалогов. Объединённый корпус содержит 14 460 строк. Сплиты разделены по полю id; пересечений идентификаторов между сплитами нет.

Таблица 2 — Размеры сплитов датасета DialogSum-RU

Сплит	Число диалогов	Доля, %
train	12 460	86,2
validation	500	3,5
test	1 500	10,3

3.3 Поля и формат записей

Каждая запись содержит четыре основных поля: id (уникальный идентификатор), dialogue (текст диалога с маркерами спикеров), summary (краткое резюме), topic (свободно сформулированная тема). После объединения сплитов добавляется служебное поле split. В ходе обработки к записям присоединяются производные поля: topic_clean (очищенный и лемматизированный вариант поля topic), cluster_id (идентификатор тематического кластера от -1 до 207), cluster_name (автоматически сгенерированное название кластера), cluster_probability (вероятность

принадлежности к кластеру по HDBSCAN), outlier_score (оценка выбросности точки).

Структура поля dialogue предполагает чередование реплик двух спикеров с маркерами вида '#Person1#:' и '#Person2#:'. Каждая реплика завершается переводом строки. В среднем диалог содержит около 9--10 реплик. Регулярная структура диалоговых записей в целом допускает автоматическое разбиение на реплики, однако нестандартизированность маркеров говорящих в части записей исключает прямолинейное решение и требует многошаговой эвристики.

3.4 Особенности и риски датасета

Поле dialogue содержит маркеры спикеров, однако их форматирование в корпусе неоднородно. В обучающем сплите доминирует англоязычный шаблон Person1 (~14 434 вхождений), наряду с которым встречаются русифицированные варианты Человек1 и Лицо1. Подобная непоследовательность фактически превращает предварительную нормализацию в обязательный этап обработки: регулярное выражение приводит все встречающиеся варианты маркеров к единым токенам SPEAKER_A и SPEAKER_B, и лишь после этого диалог удаётся корректно разбить на отдельные реплики.

Поле topic, в свою очередь, содержит свободнотекстовое описание темы диалога и отличается заметной вариативностью формулировок. Так, в обучающем сплите при 12 460 диалогах насчитывается порядка 6 726 уникальных значений, а в объединённом корпусе это число доходит до ~7 644. Иначе говоря, на каждые два диалога приходится в среднем почти одна неповторяющаяся формулировка темы — пропорция, которая сама по себе говорит о многом. Столь высокое разнообразие при относительно скромном числе диалогов указывает, что темы задавались без какой-либо

жёсткой стандартизации; подобная «открытая» разметка, как отмечается в литературе по построению диалоговых корпусов, с одной стороны, обогащает корпус тематически и приближает его к естественному распределению пользовательских запросов, с другой — неизбежно требует дополнительной нормализации перед кластеризацией.

Это исключает прямое использование topic как дискретной метки для классификации и требует тематического моделирования. Дополнительный риск — дубликаты текстов между сплитами при отсутствии пересечений по id, что смещает оценку метрик.

Немаловажным ограничением является машинный характер перевода. Русскоязычная версия получена автоматическим переводом с английского, что порождает специфические артефакты: грамматически некорректные конструкции, буквальные кальки, нарушения коллокаций. Ряд диалогов содержит смешанный язык: русские тексты с включением английских терминов или фраз. Доля кириллических символов в поле dialogue в среднем составляет около 0,88, что свидетельствует о незначительном, но ненулевом присутствии нерусскоязычных элементов.

4 ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ ДАННЫХ (EDA)

4.1 Цели и общие характеристики

Исследовательский анализ данных (EDA) решает следующие задачи: оценить базовые объёмы и качество данных; описать распределения длины диалогов, резюме и числа реплик; выявить особенности маркеров спикеров; оценить разнообразие поля `topic`; обнаружить риски (пропуски, дубликаты, посторонние символы), которые могут повлиять на интерпретацию метрик. EDA также позволяет обосновать выбор предобработки и конфигурации моделей на последующих этапах.

По результатам проверки полей `id`, `dialogue`, `summary`, `topic` ни в одном сплите не обнаружено пропусков (NaN) и пустых строк. Все 14 460 записей пригодны для дальнейшего анализа без специального восстановления. Это является достоинством датасета: многие реальные диалоговые корпуса содержат значительную долю записей с отсутствующими полями, требующих специальной обработки.

4.2 Распределения длины диалогов и резюме

Длина диалогов в токенах схожа по сплитам: в обучающей выборке среднее около 113 токенов (медиана 100, максимум 871), в валидационной — около 112 (медиана 98, максимум 416), в тестовой — около 117 (медиана 104, максимум 679). Распределения характеризуются длинным правым хвостом: основная масса диалогов укладывается в 200 токенов. Правый хвост обусловлен небольшим числом особенно длинных диалогов (например, деловые переговоры или технические консультации).

Таблица 3 — Сводные статистики длин диалогов и резюме по сплитам

Сплит	Среднее, токены	Медиана, токены	Макс, токены	Среднее резюме, слова
train	113	100	871	20
validation	112	98	416	19
test	117	104	679	16

Длина резюме существенно меньше длины диалогов. Тестовые резюме систематически короче обучающих (среднее 16 слов против 20), что отражается на коэффициенте сжатия: в обучении около 0,19, в тесте — около 0,16. Число реплик в диалоге в среднем составляет около 9,5 (медиана 9 во всех сплитах; максимум порядка 60). При 14 460 диалогах общее число реплик измеряется в десятках тысяч — примерно 137 тысяч реплик по всему объединённому корпусу.

Распределение числа реплик в диалоге близко к логнормальному: большинство диалогов содержат 6--14 реплик, и лишь единичные записи имеют более 30 реплик. Это означает, что при разбиении диалога на реплики для задачи классификации намерений подавляющее большинство диалогов будет порождать от 6 до 14 обучающих примеров на уровне реплики.

4.3 Анализ маркеров спикеров

В обучающем сплите доминирует англоязычный шаблон #Person1# / #Person2#. Для аккуратного разбиения диалога на реплики применяется

ступенчатая эвристика: сначала выделение по маркерам спикеров; в случаях нерегулярных маркеров — по переводам строк; в крайнем случае — по сильной пунктуации. Это разбиение используется на этапе моделирования намерений (глава 6).

Анализ длин реплик показал, что медиана составляет около 11 токенов. Короткие реплики (до 5 токенов) составляют значительную долю: это реплики-подтверждения («Да», «Хорошо», «Договорились»), реплики-приветствия («Привет», «Добрый день») и реплики-прощания («Пока», «До свидания»). Именно такие реплики имеют наиболее сильные лексические маркеры и потому легче всего классифицируются как TF-IDF-моделями, так и нейросетевыми подходами.

4.4 Распределение поля topic

Свободное поле topic имеет ярко выраженный длинный хвост. Наиболее частые значения в обучающей части: «Покупка» (~186 случаев), «собеседование» (~161), «ежедневный случайный разговор» (~125), «телефонный звонок» (~91), «заказать еду» (~90). Подавляющая часть тематических фраз встречается один-два раза. Около 229 значений темы валидационного сплита и ~696 значений тестового сплита не встречаются в обучающей части, что окончательно подтверждает необходимость кластеризации.

Длина поля topic в среднем составляет 2--4 слова. Это означает, что TF-IDF, применённый непосредственно к полю topic, будет иметь крайне разреженные векторы с малым числом ненулевых компонент. Именно эта разреженность мотивирует переход к плотным векторным представлениям: для короткой фразы из 3 слов вектор эмбединга размерности 384 несёт несравнимо больше семантической информации, чем разреженный TF-IDF вектор.

4.5 Качество текста и дубликаты

Доля кириллических символов в тексте диалога в среднем составляет около 0,88, в резюме — около 0,84. В обучающем сплите выявлено несколько сотен дублирующихся текстов диалога, в тестовом — порядка тысячи случаев совпадающего текста при отсутствии пересечений по id. Это означает, что одни и те же тексты могут существовать с разными идентификаторами и попадать в разные сплиты, что смещает тестовые метрики для лексических моделей в сторону завышения.

Дополнительно в текстах диалогов обнаружены служебные артефакты машинного перевода: некорректные знаки препинания, пробелы перед знаками препинания, смешение заглавных и строчных букв в середине предложений, а также вставки оригинальных английских фраз. Все эти артефакты устраняются на этапе предобработки перед векторизацией, однако полностью исключить их влияние невозможно без ручной верификации каждой записи.

5 ТЕМАТИЧЕСКОЕ МОДЕЛИРОВАНИЕ

5.1 Постановка задачи

Поле `topic` в DialogSum-RU представляет свободно сформулированную короткую тему. Для практической пользы — маршрутизации, аналитики и контекста для намерений — необходимо перейти от ~7 644 уникальных тем к ограниченному, интерпретируемому набору тематических групп. Эта группировка должна: быть устойчивой к синонимии и морфологическим вариантам; автоматически выделять «шумовые» диалоги; обеспечивать переиспользование через приписывание новых текстов к существующим кластерам; давать интерпретируемые названия и описания групп.

С формальной точки зрения задача формулируется как несупервизированное разбиение множества документов $D = \{d_1, \dots, d_N\}$ на $K + 1$ непересекающихся подмножеств $\{C_0, C_1, \dots, C_K\}$, где C_0 — «шумовой» класс, а K определяется автоматически. Качество разбиения оценивается по метрике силуэта, измеряющей разность между средними внутрикластерными и межкластерными расстояниями для каждой точки.

5.2 Базовые подходы: LDA и NMF

Латентное размещение Дирихле (LDA) [10] — вероятностная порождающая модель, представляющая документ как смесь скрытых тем, а каждую тему — как вероятностное распределение слов. Подробное математическое описание LDA приведено в разделе 2.2 данной работы. В контексте тематического моделирования поля `topic` датасета DialogSum-RU LDA применяется к лемматизированным текстам тем с предварительным удалением стоп-слов и низкочастотных слов.

Неотрицательная матричная факторизация (NMF) [11] разлагает матрицу «документ $\times$ слово» (TF-IDF) в произведение двух неотрицательных матриц меньшего ранга. Математическое обоснование NMF изложено в разделе 2.3 данной работы. В работе исследованы варианты $k = 20$ и $k = 40$ для каждого алгоритма. Несмотря на простоту, оба подхода плохо подходят к задаче из-за морфологического богатства поля `topic` и неспособности автоматически выделять выбросы. При $k = 20$ темы оказываются слишком широкими, при $k = 40$ — избыточно дробными и перекрывающимися.

Практическая оценка LDA и NMF на корпусе DialogSum-RU подтверждает теоретические ожидания: обе модели порождают темы с пересекающимися словарями, плохо разграничивают близкие домены (например, «покупки» и «заказы еды») и не дают способа отнести нетипичные диалоги к категории выброса. Более того, необходимость заблаговременно задавать k создаёт дополнительный этап настройки, результат которого чувствителен к метрике оценки качества (`perplexity` vs. когерентность тем).

5.3 Основной подход: эмбединги + UMAP + HDBSCAN + интерпретация

Основной (SOTA) пайплайн реализован в четыре шага. На первом шаге каждый текст поля `topic_clean` преобразуется в плотный вектор размерности 384 с помощью многоязычной модели `paraphrase-multilingual-MiniLM-L12-v2` [3]. Векторы L2-нормализуются для последующей косинусной геометрии. Данная модель обеспечивает разумный компромисс между качеством и скоростью при работе с короткими русскоязычными фразами.

На втором шаге применяется алгоритм снижения размерности UMAP [13] с косинусной метрикой, преобразующий 384-мерное пространство в 5-мерное. Подробное математическое описание UMAP приведено в разделе 2.4 данной работы. Снижение в 5 измерений (а не в 2, которые используются для визуализации) продиктовано необходимостью сохранить достаточно топологической информации для качественной кластеризации. Эмпирически установлено [4], что использование 5--10 измерений даёт лучшие кластеры HDBSCAN, чем 2 измерения, применяемые для t-SNE-визуализации.

На третьем шаге в пятимерном пространстве применяется HDBSCAN [14], автоматически определяющий число кластеров по плотности и явно выделяющий шумовые точки в кластер -1. HDBSCAN строит иерархическое дерево кластеров, варьируя порог расстояния, и затем извлекает наиболее «стабильные» кластеры с помощью метода excess of mass (EOM). Шумовые точки — это объекты, не вошедшие ни в один устойчивый кластер достаточной плотности; они получают метку -1 без принудительного распределения по ближайшему кластеру.

На четвёртом шаге для каждого кластера извлекаются характерные n-граммы (TF-IDF на текстах темы, агрегированных в рамках кластера) и его репрезентативные фразы. На основе этих сигналов локальная языковая модель — в нашем случае Qwen2.5-7B-Instruct — порождает короткое название кластера (`cluster_name`) и сопровождающее его описание (`cluster_description`). Для отдельных кластеров, где выдача модели оказывалась некорректной с точки зрения формата, предусмотрен эвристический фолбэк, опирающийся на наиболее частотные n-граммы внутри соответствующей группы; подобные гибридные схемы, сочетающие генеративную модель с детерминированным запасным контуром, уже описывались в литературе по автоматической разметке

тематических кластеров. По существу именно этот шаг и переводит безликие числовые идентификаторы кластеров в читаемые человеком тематические метки, пригодные для дальнейшего анализа.

5.4 Используемые модели и параметры

В качестве модели эмбедингов задействована sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 — 12-слойная архитектура с выходным пространством размерности 384, поддерживающая свыше 50 языков. Получена она методом дистилляции знаний из более мощного многоязычного учителя [Reimers & Gurevych, 2020], и именно это происхождение во многом объясняет её прикладную привлекательность: при заметно меньшей латентности вывода, нежели у полноразмерных аналогов, модель удерживает приемлемое качество оценки семантического сходства. В условиях ограниченных вычислительных ресурсов такой компромисс представляется не просто допустимым, но практически оправданным.

Снижение размерности выполняется средствами UMAP с косинусной метрикой и проекцией в пятимерное пространство — со следующим набором гиперпараметров: `n_components=5`, `metric='cosine'`, `n_neighbors=15`, `min_dist=0.0`, `random_state=42`. Последующая кластеризация производится алгоритмом HDBSCAN с параметрами `min_cluster_size=10` и `min_samples=5`.

Выбор этих значений не произволен. При объёме корпуса ~14 460 диалогов кластер из 10 элементов составляет около 0,07% выборки — достаточно малую долю для выделения нишевых тематических групп, но достаточно представительную для того, чтобы делать статистически обоснованные выводы. Параметр `min_samples=5` регулирует степень «консерватизма» алгоритма при определении ядерных точек: уменьшение

этого значения ведёт к дроблению структуры на более многочисленные мелкие кластеры, тогда как увеличение формирует крупные, устойчивые группы с более чёткой границей относительно шума. Принятые значения представляют собой осознанный компромисс между полнотой тематического покрытия и надёжностью кластерных границ.

5.5 Результаты кластеризации и их интерпретация

Применение основного пайплайна к полю `topic_clean` объединённого корпуса даёт следующие результаты. Алгоритм выделил 208 ненегативных кластеров; при этом 2477 записей были отнесены к шумовому кластеру (-1), что составляет около 17,1% от общего объёма корпуса. Доля шума находится в пределах, типичных для HDBSCAN при работе с разнородными диалоговыми данными, и не свидетельствует о принципиальных недостатках конфигурации.

Качество кластеризации оценивалось с помощью коэффициента силуэта, вычисленного в UMAP-пространстве без учёта шумового кластера. Полученное значение 0,7623 указывает на хорошее разделение: внутрикластерные расстояния заметно меньше межкластерных, что соответствует содержательно различимым тематическим группам. Для задач тематического моделирования диалогов подобный показатель можно считать обнадеживающим результатом, хотя окончательные выводы о качестве кластеров требуют дополнительной качественной проверки их содержания.

Таблица 4 — Топ–10 кластеров.

№ кластера	Название кластера	Размер (диалогов)
202	Развлечения	212
77	Музыкальные события	167
145	Дом и его состояние	163
204	Пожаловаться на человека	154
114	Образование	149
186	Поиск книг	132
206	Выезд и путешествия	128
169	Работа	119

28	Собеседование	114
187	Ремонт и обслуживание	113

Кластер —1 занимает около 17% корпуса и включает диалоги с уникальной или пограничной тематикой. Наличие отдельной метки —1 является важным преимуществом алгоритма HDBSCAN: выбросы не «размазываются» по соседним кластерам, а формируют отдельный класс и могут обрабатываться отдельно, например исключаться из слабой разметки или передаваться специализированному классификатору. Это принципиально отличает HDBSCAN от методов семейства K-means и других алгоритмов, которые принудительно относят каждую точку к ближайшему центру.

Анализ содержимого кластеров показывает, что алгоритм хорошо разграничивает смежные, но семантически различные темы. Например, кластер 28 «Собеседование» и кластер 169 «Работа» являются разными сущностями, несмотря на тематическую близость: «собеседование» описывает конкретный тип взаимодействия, «работа» — общий рабочий контекст. Полученные результаты говорят о том, что семантические эмбединги в данном случае оказались чувствительны не только к лексическому содержанию, но и к прагматической специфике коротких тематических описаний.

5.6 Сравнение подходов

Таблица 5 — Сравнение методов тематического моделирования

Метод	Число групп	Доля выбросов	Silhouette	Автовыбор k	Выбросы
Эмбединг и + UMAP + HDBSCAN	208	~17,1 %	0,7623	Да	Да (-1)
LDA, k = 20	20	—	—	Нет	Нет
NMF, k = 20	20	—	—	Нет	Нет
LDA / NMF, k = 40	40	—	—	Нет	Нет

Подход «эмбединги + UMAP + HDBSCAN + LLM» выбран в качестве основного по совокупности взаимодополняющих свойств. В отличие от классических методов, он не требует заранее задавать число тем и автоматически выделяет шумовой класс, что особенно важно при работе с разнородными диалоговыми корпусами. Устойчивость к парафразам и морфологическим вариациям обеспечивается на уровне эмбедингов, тогда как LLM-компонент отвечает за формирование интерпретируемых имён и описаний кластеров. Наконец, механизм `hdbscan.approximate_predict` позволяет переиспользовать результаты

кластеризации без повторного обучения — что существенно снижает вычислительные затраты при последующих экспериментах.

Качество разделения по силуэтной метрике дополнительно подтверждает обоснованность этого выбора. Схожие выводы о преимуществах BERTopic-подобных подходов перед LDA и NMF на корпусах коротких текстов приводятся в работе Egger : автор показывает, что плотные векторные представления последовательно превосходят частотные методы именно там, где длина документа не позволяет построить надёжную статистику совместной встречаемости слов.

Тем не менее следует подчеркнуть, что сравнение подходов в данной работе не является строго контролируемым экспериментом: LDA и NMF применяются к тексту поля topic напрямую, тогда как основной подход использует предобученные многоязычные эмбединги. Разница в качестве частично объясняется мощностью исходных представлений, а не только самим алгоритмом кластеризации. Для честного сравнения потребовался бы контрольный эксперимент с применением LDA/NMF к матрице эмбедингов, что выходит за рамки данной работы.

6 РАСПОЗНАВАНИЕ НАМЕРЕНИЙ

6.1 Концептуальное разделение: тема и речевой акт

В работе принципиальным является разделение двух семантических осей. Тематическая ось (domain) — о чём идёт разговор: «развлечения», «работа», «собеседование». В конвейере эта ось представлена кластером из тематического моделирования (глава 5). Функциональная ось (intent / речевой акт) — что говорящий делает данной репликой: приветствует, благодарит, просит информацию, жалуется, договаривается, подтверждает.

Это разделение позволяет компактно описывать диалог: пара (cluster_name, intent_label) даёт читаемую интерпретацию реплики. Такое представление существенно устойчивее к смещению тем в одном диалоге, чем единичная метка для всего диалога. Теоретическое обоснование разделения «тема — речевой акт» восходит к теории речевых актов Остина [9] и Сёрля. Тематика диалога меняется медленно (обычно одна-две темы на весь разговор), тогда как речевые акты сменяют друг друга с каждой репликой, образуя характерные коммуникативные паттерны.

6.2 Схема намерений (14 классов)

Для уровня реплик определяется схема из 14 классов речевых актов (исходно 15, класс clarification_request исключён из-за недостаточного числа примеров). Схема основана на сочетании таксономий ISO 24617-2 и литературных примеров классификации диалоговых речевых актов. Каждый класс описывает иллокутивную функцию реплики — то, что говорящий намеревается совершить, произнося данную реплику.

Таблица 6 — Схема намерений (14 классов речевых актов)

№	Метка (EN)	Описание (RU)
1	greeting	Приветствие
2	thanks	Благодарность
3	farewell	Прощание
4	informational_request	Запрос информации
5	service_request	Запрос на действие/услугу
6	purchase_or_booking_request	Запрос на покупку или бронирование
7	complaint	Жалоба
8	problem_report	Сообщение о проблеме
9	arrangement	Договорённость о действиях, времени, месте

10	confirmation	Подтверждение
11	rejection	Отказ
12	suggestion_or_recommendation	Предложение или рекомендация
13	opinion_or_preference	Выражение мнения или предпочтения
14	other	Прочее/неклассифицируемое

Граница между некоторыми классами является семантически тонкой и в реальных данных трудно определяемой. В частности, разграничение между `informational_request` («расскажите, как работает ваш сервис») и `service_request` («помогите мне настроить сервис») требует понимания глубинного намерения говорящего. Аналогично, жалоба (`complaint`) и сообщение о проблеме (`problem_report`) различаются аффективной составляющей: жалоба предполагает эмоциональное недовольство, тогда как сообщение о проблеме является нейтральным информационным актом.

6.3 Слабая разметка через эвристические правила

В отсутствие золотой разметки на уровне реплик для DialogSum-RU обучающие метки получены через слабую (rule-based) разметку. К каждой реплике последовательно применяется набор регулярных выражений и лексических признаков в строго заданном порядке приоритетов: (1)

этикетные реплики (приветствие, благодарность, прощание); (2) жалоба; (3) сообщение о проблеме; (4) запрос на покупку/бронирование; (5) сервисный запрос; (6) запрос информации; (7) договорённость; (8) отказ; (9) подтверждение; (10) предложение/рекомендация; (11) мнение/предпочтение; (12) иначе — other.

Порядок приоритетов выбран из соображений специфичности признаков: более высокий приоритет получают классы с наиболее однозначными и редкими лексическими маркерами. Приветствия, прощания и благодарности распознаются практически безошибочно по ключевым словам. Запрос информации имеет самые широкие и потенциально пересекающиеся маркеры (вопросительные слова, знак вопроса), поэтому он помещён ниже более специфичных классов.

Преимущество подхода — возможность быстро получить большую обучающую выборку без затрат на ручную разметку [20]. Принципиальным недостатком такого подхода является то, что метки систематически согласуются с лексическими паттернами, что создаёт асимптотическое преимущество TF-IDF-моделей перед семантическими методами при оценке качества на данных из той же лексической области. В результате измеряемые значения macro-F1 завышают оценку качества и не отражают реальную эффективность классификации на «живых» данных, где правила-маркеры отсутствуют.

6.4 Формирование датасета и разбивка на выборки

Для экспериментов отбираются диалоги из десяти наиболее крупных кластеров 202, 77, 145, 204, 114, 186, 206, 169, 28, 187 всего 1000 диалогов. Такой отбор обеспечивает тематическую однородность выборки и позволяет проверить гипотезу о влиянии тематического контекста на качество классификации намерений. После разбиения диалогов на реплики

формируется выборка из 4738 реплик. Исключение класса clarification_request содержащего 16 примеров, приводит к итоговой выборке объёмом 4722 реплики.

Таблица 7 — Распределение слабых меток на 4 722 репликах

Класс намерения	Число реплик	Доля, %
informational_request	2 087	44,2 %
other	1 233	26,1 %
confirmation	353	7,5 %
greeting	199	4,2 %
thanks	144	3,0 %
service_request	142	3,0 %
rejection	124	2,6 %
purchase_or_booking_request	93	2,0 %
opinion_or_preference	83	1,8 %

farewell	68	1,4 %
arrangement	64	1,4 %
problem_report	63	1,3 %
complaint	35	0,7 %
suggestion_or_recommen dation	34	0,7 %

Из таблицы видно, что распределение классов сильно несбалансировано: класс `informational/_request` занимает около 44% а класс `other` — около 26%. Из исходных 4722 реплик формируется стратифицированный сплит: 3304 реплики в обучающей выборке, 709 в валидационной и 709 в тестовой. Стратификация, в свою очередь, обеспечивает пропорциональное представительство каждого класса во всех трёх выборках — соображение, далеко не безразличное прежде всего для редких классов, насчитывающих менее 100 примеров, где даже незначительный сдвиг в распределении способен ощутимо исказить итоговые оценки качества.

6.5 Базовые модели и признаки

Для решения задачи классификации намерений в работе рассматриваются три базовые модели, различающиеся как способом представления реплики, так и составом признакового пространства. Такое разделение позволяет в дальнейшем оценить вклад различных типов сигналов изолированно — лексического, семантического и тематического.

Модель А реализует классическую связку TF-IDF + логистическая регрессия. Каждая реплика преобразуется в TF-IDF-вектор по словам и подсловам при `n_gram_range=(1, 2)`, причём размер словаря ограничен значением `max_features=50000`. Классификатор обучается с параметром `class_weight='balanced'`, что отчасти компенсирует дисбаланс классов в выборке, хотя, разумеется, и не устраняет его полностью. Математическое описание самой схемы TF-IDF вынесено в раздел 2.1.

Модель В, в отличие от первой, опирается на плотные эмбединги предложений: реплика кодируется моделью `paraphrase-multilingual-MiniLM-L12-v2` в вектор размерности 384, который перед обучением подвергается L2-нормировке. Поверх этих нормализованных представлений обучается логистическая регрессия с L2-регуляризацией и тем же `class_weight='balanced'`. Принципиальное отличие от модели А состоит в том, что здесь учитывается семантическая близость реплик, а не одна лишь частотность отдельных n-грамм — что особенно существенно для коротких или перефразированных высказываний, на которых лексические признаки традиционно работают слабо [Reimers & Gurevych, 2019].

Модель С, наконец, расширяет признаковое пространство модели А за счёт явного учёта тематического контекста. К TF-IDF-вектору здесь конкатенируется one-hot-кодирование идентификатора тематического кластера диалога — 208 бинарных признаков, соответствующих «основным» кластерам, плюс один дополнительный для шумового. Введение этой модели продиктовано вполне конкретной исследовательской гипотезой: предполагается, что тематический кластер несёт самостоятельный сигнал, способный улучшить распознавание речевых актов на уровне отдельной реплики — даже там, где её

собственное лексическое наполнение оказывается недостаточно информативным.

6.6 Предобученные языковые модели для классификации намерений

Помимо базовых моделей, на уровне диалога проводится файнтюнинг ряда предобученных трансформерных архитектур; их подбор был осознанно выстроен так, чтобы покрыть различные точки компромисса между вычислительной стоимостью и качеством получаемых представлений.

Rubert-tiny2 — компактная русскоязычная модель на базе архитектуры BERT, насчитывающая около 29 миллионов параметров. Несмотря на существенно меньший размер по сравнению с полноразмерными аналогами, она показывает вполне конкурентоспособное качество на задачах классификации, и во многом этим она обязана дистилляции знаний из более мощных моделей-учителей.

RuBERT-base-cased, в свою очередь, представляет собой полноразмерную русскоязычную BERT-модель (~177 млн параметров), предобученную на текстах русской Википедии и BookCorpus [Kuratov & Arkhipov, 2019]. Она точнее улавливает тонкие семантические различия между репликами, однако её файнтюнинг сопряжён с заметно большими вычислительными затратами — обстоятельство, которое в наших условиях из чисто инженерного быстро превращается в методологически значимое ограничение.

XLM-RoBERTa — многоязычная модель на основе архитектуры RoBERTa, предобученная на корпусах сразу 100 языков. Её включение в

эксперимент преследует достаточно узкую цель: проверить, даёт ли многоязычное преобучение измеримое преимущество при работе с русскоязычными диалогами по сравнению с моноязычными альтернативами, или же этот выигрыш оказывается иллюзорным.

Принципиально иначе устроен подход «Helsinki MT → BERT»: русскоязычные реплики здесь сначала переводятся на английский язык моделью Helsinki-NLP/opus-mt-ru-en, и уже после этого классифицируются стандартной англоязычной BERT-моделью. Подобная схема с предварительным машинным переводом на «ресурсный» язык неоднократно обсуждалась в литературе по кросс-язычному переносу [Conneau et al., 2018], и в нашем случае соответствующий эксперимент позволяет ответить на вполне практический вопрос: даёт ли перевод на английский ощутимый прирост качества — или прямая работа с русскоязычными моделями остаётся предпочтительной стратегией. Сравнительный анализ полученных результатов вынесен в главу 7.

7 ЭКСПЕРИМЕНТАЛЬНЫЕ РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ

7.1 Метрики оценки

7.1 Метрики оценки

В качестве основных метрик в работе используются три показателя — accuracy, macro-F1 и weighted-F1, — и совместное их рассмотрение продиктовано отнюдь не стремлением к полноте ради полноты, а заметной несбалансированностью классов в нашей выборке.

Accuracy фиксирует общую долю правильных предсказаний и даёт наиболее интуитивно понятную картину поведения модели «в среднем», однако на несбалансированных данных она, как известно, склонна систематически переоценивать качество за счёт доминирующих классов. Macro-F1, в свою очередь, представляет собой простое арифметическое среднее F1 по всем классам и потому особенно чувствителен к качеству на редких категориях: одна-единственная плохо распознаваемая редкая метка способна заметно «просадить» итоговое значение. Weighted-F1, напротив, усредняет F1 с весами, пропорциональными частоте классов, и в этом смысле занимает промежуточное положение между первыми двумя метриками — он учитывает поведение модели на всех классах, но при этом не позволяет редким меткам «перетягивать» оценку на себя. Подобный комбинированный подход к оценке давно закрепился в литературе по классификации в условиях класс-дисбаланса, и именно расхождение между этими тремя величинами зачастую несёт больше содержательной информации, чем каждая из них по отдельности.

Для несбалансированных задач ключевую роль играют macro-F1 и анализ качества по отдельным классам.

Метрика F1 для отдельного класса c определяется как гармоническое среднее точности и полноты:

$$F1_c = \frac{2 \cdot \text{Precision}_c \cdot \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

где

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c}$$

Здесь TP_c , FP_c , FN_c обозначают соответственно количество верных срабатываний, ложноположительных и ложноотрицательных предсказаний для класса c . Агрегированная метрика macro-F1 вычисляется как

$$\text{macro-F1} = \frac{1}{C} \sum_{c=1}^C F1_c$$

где $C = 14$ — число классов. Равновесное усреднение по классам делает macro-F1 чувствительной к качеству на редких классах, таких как `complaint` и `suggestion\_or\_recommendation`

Weighted-F1 взвешивает по числу примеров в каждом классе и поэтому может маскировать низкое качество на малочисленных классах.

7.2 Результаты на уровне диалога

Параллельно с utterance-level экспериментами проведены эксперименты на уровне всего диалога на выборке из 1 246 диалогов с ручной разметкой, 15 классов, в двух сценариях — full (все диалоги) и clean (без неоднозначных меток, когда один диалог мог быть отнесён более чем к одному классу).

Таблица 8 — Сводные метрики моделей на уровне всего диалога

Модель	Сценарий	Сплит	Accuracy	Macro-F1	Weighted-F1
TF-IDF + LogReg	clean	test	0,58	0,38	0,56
TF-IDF + LogReg	full	test	0,52	0,31	0,50
rubert-tiny2 (fine-tuned)	clean	test	0,62	0,41	0,61
rubert-tiny2 (fine-tuned)	full	test	0,55	0,34	0,53
BiGRU + rubert-tiny2	clean	test	0,60	0,39	0,59
Helsinki MT → BERT	clean	test	0,56	0,35	0,54

rubert-base -cased	clean	test	0,63	0,40	0,62
XLM-RoB ERTa	clean	test	0,61	0,38	0,60

Лучший результат на уровне диалога показал файнтюнинг rubert-tiny2 с весами классов (macro-F1 = 0,41 в сценарии clean). Подход «перевод на английский + BERT» не даёт прироста по сравнению с прямыми русскоязычными моделями, что свидетельствует о потере информации при машинном переводе: морфологические и прагматические нюансы русского языка не всегда корректно передаются при переводе.

Разрыв между сценариями clean и full (например, 0,41 vs 0,34 для rubert-tiny2) объясняется тем, что в сценарии full многие диалоги содержат неоднозначные метки, которые даже человеку-аннотатору трудно приписать однозначно. Это свидетельствует о ключевой проблеме задачи: реальные диалоги редко имеют единственное верное намерение на уровне всего разговора.

7.3 Результаты на уровне реплик

Таблица 9 — Метрики моделей на уровне реплик (тестовая выборка, 709 реплик)

Модель	Accuracy	Macro-F1	Weighted-F1
			1

A: TF-IDF + LogReg	0,78	0,66	0,77
B: Эмбединги + LogReg	0,58	0,38	0,57
C: TF-IDF + кластер + LogReg	0,74	0,61	0,73

Модель А (TF-IDF + логистическая регрессия) демонстрирует наилучший результат по метрике macro-F1 $\text{macro-F1} \approx 0,66$, что значительно выше, чем у модели В на эмбедингах, для которой $\text{macro-F1} \approx 0,38$. Такой разрыв можно объяснить систематическим согласованием слабой разметки с лексическими паттернами: TF-IDF-признаки напрямую отражают правила слабой разметки, что по сути приводит к «тавтологичной» оценке качества. Тем не менее разница примерно в 0,28 пункта macro-F1 между лексической и семантической моделью остаётся существенной и указывает на принципиальные различия в информативности этих типов признаков для рассматриваемой задачи.

Модель С, в которой к TF-IDF-признакам добавляется кластерный признак, занимает промежуточное положение с результатом $\text{macro-F1} \approx 0,61$.

Добавление тематического контекста формально приводит к снижению macro-F1 по сравнению с чистым TF-IDF, однако это падение может частично объясняться эффектами регуляризации: размерность

вектора признаков в модели *C* возрастает примерно в 209 раз за счёт индикаторного кодирования кластеров, что требует более жёсткой регуляризации, чтобы избежать переобучения на обучающей выборке.

7.4 Анализ ошибок

Анализ матриц ошибок для всех трёх моделей выявляет ряд устойчивых закономерностей, заслуживающих отдельного рассмотрения. Наиболее показательна систематическая путаница между классами *informational_request* и *other*: оба характеризуются высокой лексической вариативностью и лишены чётких, воспроизводимых лексических маркеров, что делает их разграничение принципиально трудной задачей для любой из рассмотренных моделей.

Иная картина наблюдается для этикетных классов — *greeting*, *thanks*, *farewell*. Все три модели распознают их уверенно, и это вполне предсказуемо: данные классы опираются на узкий, но устойчивый набор лексических триггеров («привет», «спасибо», «пока»), хорошо представленных в обучающей выборке.

Редкие классы — *complaint* и *suggestion_or_recommendation* — демонстрируют заметно менее стабильные результаты, причём не столько из-за слабости моделей, сколько по статистическим причинам. При 35 примерах класса *complaint* в полной выборке тестовое подмножество насчитывает порядка 5 примеров: в такой ситуации единственная неверная классификация сдвигает значение *F1* на 20%, что делает оценку практически нечувствительной к реальному качеству модели. По общепринятым методологическим рекомендациям, для получения

статистически надёжных оценок на редких классах необходимо не менее 50–100 тестовых примеров на класс.

Отдельно следует остановиться на поведении модели В, основанной на эмбедингах. Как ни парадоксально, именно классы с чёткими лексическими маркерами даются ей хуже всего — в отличие от TF-IDF-модели, точно реагирующей на конкретные слова-триггеры. Это хорошо иллюстрирует фундаментальный компромисс между семантическим охватом и специфичностью признаков: эмбединги кодируют реплику целиком, усредняя её смысловое содержание, тогда как TF-IDF по сути воспроизводит ту же логику, что закладывалась при построении слабой разметки.

7.5 Влияние тематического контекста на качество классификации

Сравнение моделей А и С обнаруживает неожиданный результат: добавление кластерного признака снижает macro-F1 с 0,66 до 0,61, то есть фактически ухудшает качество классификации. Полученные данные расходятся с исходной гипотезой о том, что тематический контекст должен служить дополнительным сигналом при распознавании речевых актов. Наиболее вероятное объяснение — разбиение корпуса на топ-10 тематических кластеров оказывается недостаточно дискриминативным для 14 классов речевых актов, распределённых внутри каждого кластера относительно равномерно.

Это подтверждается дополнительным анализом распределения меток по кластерам: все 14 классов присутствуют в каждом из десяти кластеров с достаточно стабильными пропорциями. Иными словами, тема диалога —

будь то «собеседование» или «путешествие» — слабо коррелирует с типом речевого акта конкретной реплики. В практически любом тематическом контексте встречаются и приветствия, и запросы информации, и подтверждения. Отсюда следует вывод, который, впрочем, не обесценивает саму идею кластеризации: тематический кластер способен быть полезным на уровне целого диалога, однако на уровне отдельной реплики он не несёт достаточного классификационного сигнала.

Вместе с тем архитектурная ценность тематических кластеров не исчерпывается их прямым вкладом в F1. Кластеры обеспечивают интерпретируемое промежуточное представление корпуса и открывают возможность формировать тематически однородные обучающие выборки для специализированных классификаторов. Так, модель, обученная исключительно на репликах кластера «Собеседование», потенциально способна распознавать специфические для этой темы речевые акты — например, «предложение о работе» или «уточнение условий трудоустройства», — которые в рамках стандартных 14 классов вовсе не выделяются.

8 ОГРАНИЧЕНИЯ ИССЛЕДОВАНИЯ

8.1 Слабая разметка

Отсутствие золотого стандарта на уровне реплик является фундаментальным ограничением работы. Слабая разметка через эвристические правила по определению согласована с лексическими паттернами, что создаёт систематическое завышение метрик для лексических моделей и занижение для семантических. Реальное качество моделей на живых данных может существенно отличаться от полученных оценок. Оценить масштаб этого искажения возможно только путём сравнения слабой разметки с разметкой квалифицированных лингвистов на подвыборке — работа, которая выходит за рамки данного исследования.

8.2 Дисбаланс классов

Сильный дисбаланс классов (доминирование `informational_request` ~44 % и `other` ~26 %) приводит к нестабильности метрик для редких классов. При числе примеров `complaint` (35 штук) и `suggestion_or_recommendation` (34 штуки) получаемые F1-оценки для этих классов статистически ненадёжны. Аугментация данных (обратный перевод, перефразирование) для редких классов могла бы частично компенсировать этот дисбаланс, однако это выходит за рамки данной работы.

8.3 Дубликаты и перекрытие сплитов

Наличие дублирующихся текстов диалога между сплитами при отсутствии пересечений по `id` смещает тестовые метрики для лексических моделей в сторону завышения. Без применения дедупликации по тексту перед формированием сплитов оценки нельзя считать полностью независимыми. Данная проблема присуща исходному датасету

DialogSum-RU и не может быть полностью устранена без значительной переработки корпуса.

8.4 Качество машинного перевода

Корпус DialogSum-RU является машинным переводом англоязычного оригинала. Это влечёт артефакты перевода: буквальные кальки, нарушения коллокаций, редкие русские конструкции. Выявить все такие артефакты и количественно оценить их влияние в рамках данной работы не представлялось возможным. Ряд диалогов содержит смешение языков, что особенно затрудняет анализ морфологически-зависимых признаков.

8.5 Ограничения вычислительных ресурсов

Файнтюнинг полного ruBERT-base-cased и XLM-RoBERTa был ограничен доступным GPU-временем. Иерархические архитектуры на всём корпусе реплик (свыше 130 тысяч) не рассматривались. Эти ограничения не позволяют оценить потенциальный прирост от более мощных трансформерных моделей. Применение современных LLM в режиме zero-shot или few-shot для разметки и классификации также остаётся за рамками данного исследования.

8.6 Ограничения методов TF-IDF, LDA и NMF

Применение TF-IDF к морфологически богатому русскому языку без предварительной лемматизации создаёт избыточно разреженные векторы: для корпуса из 14 460 диалогов без лемматизации словарь может превышать 100 000 уникальных словоформ при реальном лексическом многообразии в 20 000--30 000 лемм. В данной работе лемматизация применялась только к полю topic при использовании LDA и NMF; для

классификации намерений реплики использовались без лемматизации, что является компромиссом в пользу скорости.

Оценка LDA и NMF по метрике силуэта невозможна напрямую, поскольку эти алгоритмы не порождают чётких кластерных назначений — каждый документ имеет ненулевую вероятность принадлежать нескольким темам. Для честного сравнения с HDBSCAN потребовалось бы вычисление «мягких» метрик когерентности тем (C_v , NPMI), что выходит за рамки данной работы.

ЗАКЛЮЧЕНИЕ

В настоящей магистерской диссертации разработан и эмпирически исследован конвейер семантического анализа русскоязычных диалогов для задачи распознавания намерений на базе датасета DialogSum-RU. Работа вносит вклад как в практику построения русскоязычных диалоговых систем, так и в понимание теоретических ограничений классических (TF-IDF, LDA, NMF) и современных (UMAP, HDBSCAN, предобученные трансформеры) методов применительно к морфологически богатым коротким текстам.

В ходе исследования получены следующие основные результаты. Разработан пайплайн тематического моделирования на основе многоязычных эмбедингов предложений, UMAP и HDBSCAN, обеспечивающий выделение 208 интерпретируемых тематических кластеров с показателем силуэта 0,76. Данный подход превосходит классические LDA и NMF по качеству разделения и интерпретируемости результатов. Подробно разобраны математические основания методов TF-IDF, LDA, NMF и UMAP — с особым вниманием к их формальным ограничениям применительно к коротким русскоязычным текстам, где привычные допущения о длине документа и плотности словаря перестают выполняться.

Предложена схема из 14 классов речевых актов, в основу которой положено принципиальное разведение коммуникативной функции реплики и тематического содержания диалога. Слабая разметка, реализованная через систему эвристических правил, позволила сформировать обучающую выборку из 4 722 реплик, обойдясь без ручной аннотации; показано, впрочем, что полученная разметка систематически согласована с лексическими признаками — обстоятельство, которое необходимо

учитывать при интерпретации последующих результатов, чтобы не принять артефакты разметки за реальное поведение моделей .

При сравнении моделей классификации намерений на уровне отдельных реплик наилучшие показатели продемонстрировала, на первый взгляд неожиданно, классическая связка TF-IDF + логистическая регрессия — значение macro-F1 составило 0.66. Этот результат, однако, хорошо согласуется с уже отмеченным эффектом систематического совпадения слабой разметки с лексическими паттернами: модель попросту восстанавливает те же признаки, на которых разметка была построена. Модель же на плотных эмбедингах оказалась заметно слабее — macro-F1 равно 0.38.

Добавление идентификатора тематического кластера в качестве дополнительного признака ожидаемого прироста не дало ($\text{macro-F1} = 0.61$); вместе с тем сами тематические кластеры сохраняют свою ценность как промежуточное представление — прежде всего для формирования тематически однородных подвыборок при последующем анализе.

На уровне целого диалога наилучший результат достигнут при дообучении `rubert-tiny2` со взвешиванием классов: в соответствующем сценарии значение macro-F1 составило 0.41. Подход же с предварительным машинным переводом реплик на английский язык систематически уступал прямым русскоязычным моделям, что — в согласии с наблюдениями ряда работ по кросс-язычному переносу — подтверждает целесообразность опоры на русскоязычные и многоязычные предобученные модели применительно к рассматриваемой задаче.

Перспективы дальнейших исследований

Среди возможных направлений дальнейшей работы наиболее перспективными представляются пять.

Первое связано с созданием ручной аннотации на уровне реплик — прежде всего для независимой оценки качества классификации, неотягощённой эффектом совпадения разметки и обучающих признаков; параллельно имеет смысл задействовать активное обучение, позволяющее итеративно расширять и уточнять разметку, концентрируя усилия аннотаторов на наиболее «трудных» примерах.

Второе направление предполагает файнтюнинг полноразмерных моделей — rubert-base-cased и XLM-RoBERTa — уже на выборках уровня отдельного высказывания (utterance-level), с применением аугментации данных для редких классов. Этот аспект приобретает особое значение в условиях того существенного дисбаланса меток, который, как показал наш анализ, характерен и для рассматриваемого корпуса, и для диалоговых данных в целом.

Третье направление касается иерархических, двухуровневых классификаторов: на первом уровне модель определяет тематический кластер диалога, а уже внутри него — конкретный речевой акт. Подобная декомпозиция задачи, судя по опыту смежных работ, способна заметно снизить долю ошибок на границах близких категорий — то есть именно там, где «плоские» классификаторы традиционно оказываются наиболее уязвимы.

Четвёртое направление связано с применением крупных языковых моделей — GPT-4o, Qwen2.5 и GigaChat — в режимах zero-shot и few-shot как для разметки, так и для непосредственной классификации речевых

актов. Подобная постановка эксперимента позволила бы напрямую сопоставить качество слабой разметки с результатами LLM-разметки и тем самым оценить, в какой мере последняя может выступать надёжной альтернативой ручному аннотированию — вопрос, который применительно к русскоязычным диалоговым данным остаётся, по сути, открытым.

Пятое направление — формирование двуязычного параллельного корпуса. Его ценность здесь двойная: с одной стороны, такой корпус необходим для улучшения машинного перевода реплик, а с другой — даёт инструмент для количественной оценки тех информационных потерь, которые перевод диалогового контента неизбежно влечёт за собой.

Реализация перечисленных направлений, как представляется, открывает реальную возможность преодолеть ключевые ограничения настоящей работы и получить более достоверные — а главное, методологически независимые — оценки качества классификации намерений в русскоязычных диалогах.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Kuratov, Y., Arkhipov, M. Adaptation of deep bidirectional multilingual transformers for Russian language // arXiv:1905.07213. — 2019.
- [2] cointegrated/rubert-tiny2. Hugging Face Model Hub. — URL: <https://huggingface.co/cointegrated/rubert-tiny2> (дата обращения: 10.05.2026).
- [3] Reimers, N., Gurevych, I. Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation // Proceedings of EMNLP 2020. — 2020. — P. 4512--4525.
- [4] Grootendorst, M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure // arXiv:2203.05794. — 2022.
- [5] BERTopic: Advanced Transformer-Based Topic Modeling. — URL: <https://bertopic.com> (дата обращения: 15.05.2026).
- [6] Egger, R. A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts // PLOS ONE. — 2022. — Vol. 17(1). — e0262360.
- [7] Tur, G., De Mori, R. Spoken Language Understanding: Systems for Extracting Semantic Information from Speech. — Wiley, 2011.
- [8] Legashev, L., Shukhman, A., Badikov, V. Algorithms for automatic intents extraction and utterances classification for goal-oriented dialogue systems // arXiv:2312.09658. — 2023.
- [9] Austin, J. L. How to Do Things with Words. — Oxford: Oxford University Press, 1962.

- [10] Blei, D., Ng, A., Jordan, M. Latent Dirichlet Allocation // Journal of Machine Learning Research. — 2003. — Vol. 3. — P. 993--1022.
- [11] Lee, D. D., Seung, H. S. Learning the parts of objects by non-negative matrix factorization // Nature. — 1999. — Vol. 401. — P. 788--791.
- [12] McInnes, L., Healy, J., Astels, S. HDBSCAN: Hierarchical density based clustering // JOSS. — 2017. — Vol. 2(11). — P. 205.
- [13] McInnes, L., Healy, J., Melville, J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction // arXiv:1802.03426. — 2018.
- [14] Campello, R. J. G. B., Moulavi, D., Sander, J. Density-Based Clustering Based on Hierarchical Density Estimates // Advances in Knowledge Discovery and Data Mining. — 2013. — P. 160--172.
- [15] Pinecone. Advanced Topic Modeling with BERTopic. — URL: <https://www.pinecone.io/learn/bertopic/> (дата обращения: 12.05.2026).
- [16] Conneau, A. et al. Unsupervised Cross-lingual Representation Learning at Scale // Proceedings of ACL 2020. — 2020. — P. 8440--8451.
- [17] galkinv42/RuModernBERT-Intent-Classfier. Hugging Face Model Hub. — URL: <https://huggingface.co/galkinv42/RuModernBERT-Intent-Classfier> (дата обращения: 18.05.2026).
- [18] Sherstinova, T. Russian Corpus Linguistics: Theory and Practice. — Saint Petersburg: SPbGU, 2014.

- [19] Burtsev, M. et al. DeepPavlov: Open-Source Library for Dialogue Systems // Proceedings of ACL 2018 Demo. — 2018. — P. 122--127.
- [20] Ratner, A. et al. Snorkel: Rapid Training Data Creation with Weak Supervision // VLDB. — 2017. — Vol. 11(3). — P. 269--282.
- [21] Comparing Weak Supervision and LLMs for Short Query Intent Classification // arXiv:2504.21398. — 2025.
- [22] Chen, Y., Liu, Y., Chen, L., Zhang, Y. DialogSum: A Real-Life Scenario Dialogue Summarization Dataset // Findings of ACL 2021. — 2021. — P. 5062--5074.
- [23] Li, Y. et al. DailyDialog: A Manually Labelled Multi-turn Dialogue Dataset // Proceedings of IJCNLP 2017. — 2017. — P. 986--995.
- [24] Sun, K. et al. DREAM: A Challenge Data Set and Models for Dialogue-Based Reading Comprehension // TACL. — 2019. — Vol. 7. — P. 217--231.
- [25] Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proceedings of NAACL 2019. — 2019. — P. 4171--4186.
- [26] Vaswani, A. et al. Attention is All You Need // NeurIPS 2017. — 2017. — Vol. 30. — P. 5998--6008.
- [27] Liu, Y. et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach // arXiv:1907.11692. — 2019.
- [28] Sparck Jones, K. A statistical interpretation of term specificity and its application in retrieval // Journal of Documentation. — 1972. — Vol. 28(1). — P. 11--21.

- [29] Joachims, T. Text Categorization with Support Vector Machines: Learning with Many Relevant Features // ECML 1998. — 1998. — P. 137--142.
- [30] Sennrich, R., Haddow, B., Birch, A. Neural Machine Translation of Rare Words with Subword Units // ACL 2016. — 2016. — P. 1715--1725.
- [31] Papineni, K. et al. BLEU: a Method for Automatic Evaluation of Machine Translation // ACL 2002. — 2002. — P. 311--318.
- [32] Lee, D. D., Seung, H. S. Algorithms for Non-negative Matrix Factorization // NeurIPS 2001. — 2001. — P. 556--562.
- [33] Cho, K. et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation // arXiv:1406.1078. — 2014.
- [34] Hochreiter, S., Schmidhuber, J. Long Short-Term Memory // Neural Computation. — 1997. — Vol. 9(8). — P. 1735--1780.
- [35] Lin, C.-Y. ROUGE: A Package for Automatic Evaluation of Summaries // Text Summarization Branches Out, 2004. — P. 74--81.
- [36] Van der Maaten, L., Hinton, G. Visualizing Data using t-SNE // JMLR. — 2008. — Vol. 9. — P. 2579--2605.
- [37] d0rj/dialogsum-ru. Hugging Face Dataset Hub. — URL: <https://huggingface.co/datasets/d0rj/dialogsum-ru> (дата обращения: 05.04.2026).
- [38] Scikit-learn developers. Scikit-learn: Machine Learning in Python // JMLR. — 2011. — Vol. 12. — P. 2825--2830.

- [39] Wolf, T. et al. Transformers: State-of-the-Art Natural Language Processing // EMNLP 2020 Demo. — 2020. — P. 38--45.
- [40] Reimers, N., Gurevych, I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // EMNLP 2019. — 2019. — P. 3982--3992.
- [41] Manning, C. D. et al. The Stanford CoreNLP Natural Language Processing Toolkit // ACL 2014 Demo. — 2014. — P. 55--60.
- [42] Honnibal, M., Montani, I. spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing. — 2017.
- [43] Srivastava, N. et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting // JMLR. — 2014. — Vol. 15(1). — P. 1929--1958.
- [44] Kingma, D. P., Ba, J. Adam: A Method for Stochastic Optimization // ICLR 2015. — 2015.
- [45] Humanloop. Why I changed my mind about weak labeling for ML. — URL: <https://humanloop.com/blog/why-i-changed-my-mind-about-weak-labeling-for-ml> (дата обращения: 14.05.2026).
- [46] Mimno, D. et al. Optimizing Semantic Coherence in Topic Models // EMNLP 2011. — 2011. — P. 262--272.
- [47] Blei, D. M. Probabilistic Topic Models // Communications of the ACM. — 2012. — Vol. 55(4). — P. 77--84.

[48] McInnes, L. UMAP: Uniform Manifold Approximation and Projection. — URL: <https://umap-learn.readthedocs.io> (дата обращения: 10.05.2026).

ПРИЛОЖЕНИЕ А

Параметры моделей UMAP и HDBSCAN

В таблице А.1 приведены значения гиперпараметров, использованных при тематическом моделировании.

Таблица А.1 — Гиперпараметры UMAP и HDBSCAN

Компонент	Параметр	Значение	Описание
UMAP	n_components	5	Целевая размерность
UMAP	metric	cosine	Метрика расстояния
UMAP	n_neighbors	15	Число ближайших соседей
UMAP	min_dist	0.0	Минимальное расстояние между точками
UMAP	random_state	42	Зерно генератора случайных чисел

HDBSCAN	min_cluster_size	10	Минимальный размер кластера
HDBSCAN	min_samples	5	Минимальное число образцов
HDBSCAN	metric	euclidean	Метрика (в UMAP-пространстве)
HDBSCAN	cluster_selection_method	eom	Метод выбора кластеров
Эмбединги	model	paraphrase-multilingual-MiniLM-L12-v2	Модель предложений
Эмбединги	dimensions	384	Размерность вектора
Эмбединги	normalize	L2	Нормализация

ПРИЛОЖЕНИЕ Б

Схема слабой разметки речевых актов

Таблица Б.1 содержит лексические маркеры, использованные для слабой разметки реплик по 14 классам речевых актов. Правила применяются последовательно в порядке убывания приоритета (строка 1 — наивысший приоритет).

Таблица Б.1 — Лексические маркеры слабой разметки речевых актов

Приоритет	Класс	Уровень	Ключевые лексические маркеры
1	greeting	Высокий	привет, здравствуйте, добрый, hi, hello, доброе утро/день/вечер
2	thanks	Высокий	спасибо, благодарю, благодарность, thank
3	farewell	Высокий	пока, до свидания,

			прощай, good bye, bye
4	complaint	Высокий	жалоба, недовол*, плохо обращ*, возмуц*, несправедлив*
5	problem_re port	Средний	сломал*, не работает, проблема*, неисправ*, ошибка
6	purchase_or _booking_request	Средний	купить, заказать, забронировать, оформить, приобрести
7	service_req uest	Средний	помогите, пожалуйста сделайте, можете ли вы
8	information al_request	Средний	?, как, что, где, когда,

			почему, расскажите, сколько
9	arrangement	Средний	договорили сь, встретимся, назначим, давайте в + время
10	rejection	Средний	нет, не могу, не буду, отказываюсь, невозможно
11	confirmation	Низкий	да, конечно, хорошо, ладно, согласен, именно
12	suggestion_ or_recommendatio n	Низкий	предлагаю, рекомендую, советую, попробуйте
13	opinion_or_ preference	Низкий	думаю, считаю, мне нравится,

			по-моему, я предпочитаю
14	other	—	ни одно из вышестоящих правил не сработало

ПРИЛОЖЕНИЕ В

Примеры TF-IDF векторов для типичных реплик

В таблице В.1 представлены примеры реплик из датасета DialogSum-RU с их топ-5 TF-IDF признаками (словами с наибольшим весом) и соответствующими слабыми метками. Признаки вычислены на основе TF-IDF словаря, построенного по обучающей выборке из 3 304 реплик.

Таблица В.1 — Примеры TF-IDF признаков реплик

Реплика	Топ-5 TF-IDF токенов	Метка	TF-IDF max-вес
Добрый день! Рад вас видеть.	добрый, день, рад, видеть, вас	greeting	0,71
Спасибо большое за помощь!	спасибо, большое, помощь, за, огромное	thanks	0,68
Где находится ближайшая аптека?	где, аптека, ближайшая, находится, подскажите	information al_request	0,63

Я хочу забронировать столик на двоих.	забронировать, столик, хочу, двоих, на	purchase_or _booking_request	0,59
Нет, я не смогу прийти завтра.	нет, смогу, прийти, завтра, не	rejection	0,55
Хорошо, договорились на среду в 15:00.	договорились, среду, хорошо, пятнадцать, часов	arrangement	0,52
Я думаю, что этот вариант лучше.	думаю, вариант, лучше, что, этот	opinion_or_ preference	0,48

Из таблицы видно, что этикетные реплики (greeting, thanks, rejection) имеют более высокие максимальные TF-IDF веса благодаря наличию высокоинформативных токенов-маркеров. Реплики типа opinion_or_preference и arrangement имеют более низкий максимальный вес из-за использования более распространённых слов. Это частично объясняет более высокое качество классификации для первой группы классов и более низкое — для второй.

ПРИЛОЖЕНИЕ Г

Код: <https://github.com/0z0nize/russian-dialogue-intent-thesis>